

Deteksi Kebersihan Permukaan Sayur Menggunakan Ekstraksi Fitur GLCM dan SVM

Hamdan Azizul Hakim¹, Muhammad Alif Febriansyah², Aryo Adi Putro³, Sadiya Maritza⁴

^{1,2,3} Program Studi Teknik Informatika, Jurusan Teknologi Informasi, Politeknik Negeri Malang

¹hamdanizul24@gmail.com, ²aliffebriansyah@gmail.com,

³aryoadiputro@gmail.com, ⁴sadiyamaritza8924@gmail.com

Abstrak

Kualitas visual foto produk sayuran pada *marketplace* berperan penting dalam membentuk persepsi konsumen dan memengaruhi keputusan pembelian. Foto sayuran yang menampilkan permukaan kotor atau bercacat dapat menurunkan kredibilitas penjual dan platform sehingga diperlukan mekanisme verifikasi otomatis sebelum unggahan produk ditampilkan. Penelitian ini membandingkan kinerja algoritma *Support Vector Machine* (SVM) dan *K-Nearest Neighbor* (KNN) menggunakan *pipeline* pemrosesan citra yang sama. Tahapan *pipeline* meliputi *resizing*, *Gaussian filtering*, normalisasi, segmentasi menggunakan *GrabCut*, dan ekstraksi fitur warna (HSV) serta tekstur (GLCM). Pemilihan fitur tekstur mengikuti temuan penelitian yang menunjukkan bahwa GLCM efektif untuk membedakan variasi permukaan pada objek sayuran. Segmentasi dan ekstraksi fitur juga telah digunakan secara luas pada sistem *grading* dan penyortiran produk sayuran. Evaluasi performa dilakukan menggunakan metrik akurasi, *precision*, *recall*, dan *F1-Score*. Hasil pengujian menunjukkan bahwa SVM memiliki performa klasifikasi yang lebih stabil dibandingkan KNN pada verifikasi kebersihan permukaan sayuran dengan *pipeline* yang sama. Penelitian ini memberikan kontribusi praktis dalam bentuk rekomendasi model yang sesuai untuk integrasi pada proses unggah foto di *marketplace* sehingga kualitas tampilan produk dapat terjaga.

Kata kunci: SVM, KNN, GLCM, HSV, verifikasi unggahan, *marketplace*.

1. Pendahuluan

Marketplace produk sayuran segar mengandalkan citra visual sebagai sarana utama bagi konsumen untuk menilai kualitas dan kebersihan sayuran. Foto produk berperan sebagai representasi langsung kondisi barang sehingga ketidaksesuaian visual, seperti permukaan yang tampak kotor atau cacat, dapat menurunkan kepercayaan dan meningkatkan risiko komplain. Pemeriksaan manual terhadap unggahan gambar tidak dapat diterapkan secara efektif karena tingginya volume unggahan serta beragamnya kondisi pengambilan gambar. Kondisi ini menuntut adanya sistem verifikasi otomatis yang mampu bekerja secara cepat, konsisten, dan efisien (Hemamalini et al., 2022).

Pendekatan berbasis pemrosesan citra dan *machine learning* telah digunakan secara luas untuk pemeriksaan kualitas produk pertanian. Segmentasi berbasis *GrabCut* dan metode *clustering* terbukti membantu memisahkan objek dari latar sehingga fitur visual dapat dianalisis dengan lebih akurat (Bhargava et al., 2022). Fitur warna dan tekstur merupakan kombinasi yang efektif untuk membedakan permukaan alami sayuran dari anomali visual. Analisis tekstur menggunakan GLCM memiliki sensitivitas tinggi terhadap perubahan pola permukaan sehingga relevan untuk verifikasi kebersihan citra unggahan (Kabir et al., 2024).

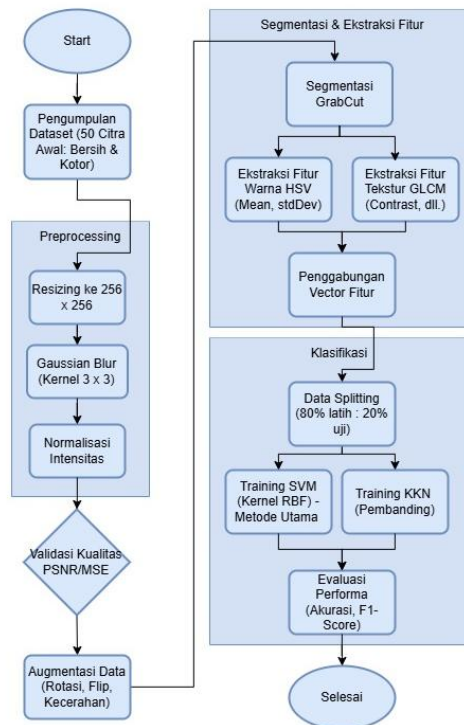
Penelitian pada *Hyperspectral Imaging* (HSI) dan *Convolutional Neural Network* (CNN) menunjukkan akurasi tinggi pada deteksi residu pestisida (Hu et al., 2023) dan cacat permukaan (Li et al., 2022) tetapi membutuhkan komputasi besar serta infrastruktur perangkat keras yang lebih kompleks sehingga kurang sesuai untuk proses verifikasi unggahan pada *marketplace* yang membutuhkan respons cepat. Oleh sebab itu pendekatan berbasis fitur klasik tetap relevan untuk sistem operasional berskala besar yang membutuhkan efisiensi komputasi.

Penelitian ini bertujuan untuk membandingkan kinerja SVM dan KNN pada klasifikasi kebersihan permukaan gambar sayuran dengan *pipeline* yang sama. Kedua algoritma diuji dengan fitur yang identik untuk memastikan bahwa perbedaan performa disebabkan oleh karakteristik algoritma, bukan perbedaan *input*. Evaluasi meliputi akurasi, *precision*, *recall*, dan *F1-Score*. Hasil penelitian diharapkan memberikan rekomendasi model yang paling sesuai untuk diterapkan sebagai sistem verifikasi otomatis pada proses unggah foto *marketplace*.

2. Metode

Penelitian ini menerapkan alur kerja yang dioptimalkan untuk efisiensi komputasi menggunakan Python (OpenCV, Scikit-learn). Alur

penelitian secara keseluruhan dapat dilihat pada gambar berikut.



Gambar 1. Diagram Alir Penelitian

2.1. Pengumpulan Dataset

Data awal terdiri dari 50 citra sayur yang dikumpulkan dan ditetapkan menjadi dua kelas dengan jumlah yang setara: "Bersih" dan "Kotor". Citra diambil dengan variasi latar belakang dan pencahayaan untuk merepresentasikan kondisi nyata.

2.2. Preprocessing Citra

Sebelum dilakukan perbanyakkan data, setiap citra mentah (*raw image*) diproses terlebih dahulu untuk menstandarisasi kualitas dan dimensi. Langkah ini dilakukan di awal agar operasi filter tidak perlu diulang berkali-kali pada citra hasil augmentasi nantinya.

1. **Resizing**
Citra diubah ukurannya menjadi 256×256 piksel menggunakan interpolasi *INTER_AREA* untuk menyeragamkan *input* model (Li et al., 2022).
2. **Gaussian Blur**
Filter Gaussian dengan kernel (3, 3) digunakan untuk mereduksi *noise* dan meningkatkan kualitas visual citra tanpa menghilangkan detail kotoran yang signifikan (Bhargava et al., 2022).
3. **Normalisasi Intensitas**
Nilai piksel dikonversi ke rentang [0, 1] (*float32*) untuk stabilitas numerik saat perhitungan matriks. Kualitas tahap ini divalidasi dengan menghitung PSNR dan MSE terhadap citra asli (Hu et al., 2023).

2.3. Augmentasi Data

Setelah citra bersih dari *noise* dan memiliki ukuran standar, teknik augmentasi diterapkan untuk memperbanyak sampel latih. Penempatan tahap ini di akhir *preprocessing* mempercepat proses penyiapan data secara signifikan. Teknik yang digunakan meliputi:

1. Rotasi: 90° , 180° , dan 270° .
2. Pencerminan (*Flipping*): Horizontal dan Vertikal.
3. Variasi Kecerahan: Penyesuaian intensitas (*brightness*) sebesar ± 0.12 .

2.4. Segmentasi dan Ekstraksi Fitur

Citra hasil augmentasi kemudian masuk ke tahap ekstraksi informasi:

1. **Segmentasi GrabCut**
Memisahkan *foreground* (sayur) dari *background* menggunakan inisialisasi *rect* otomatis (Bhargava et al., 2022).
2. **Fitur Warna (HSV)**
Menghitung *Mean* dan *Standard Deviation* dari kanal H, S, dan V.
3. **Fitur Tekstur (GLCM)**
Citra hasil segmentasi dikonversi ke *grayscale*, lalu diekstraksi fitur tekstur berbasis GLCM. Sebanyak sepuluh parameter statistik dihitung untuk merepresentasikan karakteristik permukaan, meliputi *Contrast*, *Correlation*, *Energy*, *Homogeneity*, *ASM*, *Total Variance*, *Difference Variance*, *Maximum Probability*, *Joint Entropy*, dan *Difference Entropy* (Kabir et al., 2024).

2.5. Klasifikasi

Vektor fitur gabungan dilatih menggunakan *Support Vector Machine* (SVM) dengan kernel RBF dan dibandingkan dengan *K-Nearest Neighbor* (KNN). Evaluasi dilakukan dengan skenario *split* data 80:20.

3. Hasil dan Pembahasan

3.1. Analisis Kualitas Preprocessing

Strategi melakukan *preprocessing* sebelum augmentasi terbukti efisien mempertahankan kualitas citra. Nilai *Peak Signal-to-Noise Ratio* (PSNR) pada citra bersih mencapai rata-rata 48.11 dB dengan MSE 1.62. Nilai PSNR yang tinggi mengindikasikan bahwa proses *smoothing* dan *resizing* berhasil menghilangkan *noise* tanpa merusak informasi fitur utama, sehingga aman untuk dijadikan basis augmentasi data.

3.2. Efektivitas Fitur Tekstur dan Warna

Hasil ekstraksi fitur menunjukkan bahwa fitur GLCM, terutama *Contrast* dan *Entropy*, memiliki diskriminansi tinggi antara permukaan bersih (halus) dan kotor (kasar). Fitur warna HSV melengkapi

deteksi pada noda tanah yang memiliki saturasi berbeda dengan kulit wortel.

3.3 Performa Klasifikasi (SVM vs KNN)

Berdasarkan pengujian pada dataset yang telah diaugmentasi (*Split* 80:20), SVM menunjukkan performa yang lebih superior dan stabil dibandingkan KNN:

Tabel 1. Perbandingan Hasil

Metrik	SVM (%)	KNN (%)
Akurasi	98.75	97.5
Precision	98.78	87.62
Recall	98.75	97.5
F1-Score	98.75	97.5

Keunggulan SVM ini menegaskan temuan literatur bahwa SVM lebih *robust* dalam menangani data berdimensi tinggi (gabungan HSV dan GLCM) dan memiliki generalisasi yang lebih baik pada batas keputusan (*decision boundary*) yang kompleks dibandingkan KNN (Hemamalini et al., 2022). Tingginya akurasi juga membuktikan bahwa strategi augmentasi yang diterapkan berhasil merepresentasikan variasi data yang cukup untuk pelatihan model.

4. Kesimpulan

Penelitian ini berhasil mengembangkan sistem deteksi kebersihan wortel dengan pendekatan efisien, di mana augmentasi data ditempatkan di akhir tahap *preprocessing*. Validasi menggunakan PSNR membuktikan kualitas citra tetap terjaga, sementara penggunaan SVM menghasilkan akurasi klasifikasi mencapai 98.75%. Metode ini terbukti lebih efektif dibandingkan KNN (97.50%) dan siap diterapkan sebagai solusi inspeksi otomatis yang hemat sumber daya komputasi.

Daftar Pustaka:

- Bhargava, A., Bansal, A., & Goyal, V. (2022). Machine Learning-Based Detection and Sorting of Multiple Vegetables and Fruits. *Food Analytical Methods*, 15(1), 228–242. <https://doi.org/10.1007/s12161-021-02086-1>
- Hemamalini, V., Rajarajeswari, S., Nachiyappan, S., Sambath, M., Devi, T., Singh, B. K., & Raghuvanshi, A. (2022). Food Quality Inspection and Grading Using Efficient Image Segmentation and Machine Learning-Based System. *Journal of Food Quality*, 2022. <https://doi.org/10.1155/2022/5262294>
- Hu, Y., Ma, B., Wang, H., Zhang, Y., Li, Y., & Yu, G. (2023). Detecting different pesticide residues on Hami melon surface using hyperspectral imaging combined with 1D-CNN and information fusion. *Frontiers in Plant Science*, 14. <https://doi.org/10.3389/fpls.2023.1105601>
- Kabir, M., Unal, F., Akinci, T. C., Martinez-Morales, A. A., & Ekici, S. (2024). Revealing GLCM Metric Variations across a Plant Disease Dataset: A Comprehensive Examination and Future Prospects for Enhanced Deep Learning Applications. *Electronics (Switzerland)*, 13(12). <https://doi.org/10.3390/electronics13122299>
- Li, Y., Xue, J., Wang, K., Zhang, M., & Li, Z. (2022). Surface Defect Detection of Fresh-Cut Cauliflowers Based on Convolutional Neural Network with Transfer Learning. *Foods*, 11(18). <https://doi.org/10.3390/foods11182915>